

**CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA**

Faculdade de Tecnologia da Baixada Santista "Rubens Lara"

Curso Superior de Tecnologia em Ciência de Dados

**Octávio Augusto dos Passos Teodoro**

**ANÁLISE DE SENTIMENTOS EM REDES SOCIAIS: UMA FERRAMENTA  
ESTRATÉGICA PARA O MONITORAMENTO DA OPINIÃO PÚBLICA SOBRE  
DECISÕES GOVERNAMENTAIS**

*Relatório Final de Iniciação Científica*

Santos – SP

2026

**Octávio Augusto dos Passos Teodoro**

**ANÁLISE DE SENTIMENTOS EM REDES SOCIAIS: UMA FERRAMENTA  
ESTRATÉGICA PARA O MONITORAMENTO DA OPINIÃO PÚBLICA SOBRE  
DECISÕES GOVERNAMENTAIS**

*Relatório Final de Iniciação Científica apresentado à  
Faculdade de Tecnologia da Baixada Santista  
"Rubens Lara", Curso Superior de Tecnologia em  
Ciência de Dados.*

*Orientador: Prof. Maurício Conceição*

Santos – SP

2026

## **LISTA DE ABREVIATURAS E SIGLAS**

**ABNT** – Associação Brasileira de Normas Técnicas

**API** – Application Programming Interface

**ANOVA** – Analysis of Variance (Análise de Variância)

**FATEC BS** – Faculdade de Tecnologia da Baixada Santista

**NLP** – Natural Language Processing

**NLTK** – Natural Language Toolkit

**PIC** – Projeto de Iniciação Científica

**PLN** – Processamento de Linguagem Natural

**SVM** – Support Vector Machine

## RESUMO

O presente relatório apresenta os resultados do Projeto de Iniciação Científica desenvolvido na Faculdade de Tecnologia da Baixada Santista, cujo objetivo foi mensurar, por meio de técnicas de Processamento de Linguagem Natural (PLN), o impacto da tributação incidente sobre plataformas de anúncios digitais — Google Ads e Meta Ads — na percepção pública do mercado de marketing digital brasileiro em 2026. A pesquisa empregou um pipeline de dados automatizado em Python, com extração via API do X/Twitter (Tweepy), análise de sentimentos (NLTK e TextBlob) e validação estatística no Jamovi. Os resultados demonstraram impacto negativo estatisticamente significativo: 76% das opiniões analisadas (base: dataset sintético calibrado,  $n=300$ ) durante o período do Evento tributário foram classificadas como negativas, com queda de polaridade média de  $-0,14$  (Pré-Evento) para  $-0,37$  (Evento), representando redução de 157,8%. A Análise de Variância One-Way (ANOVA de Welch) confirmou a significância das diferenças entre períodos para a Polaridade ( $F(2, 196,3) = 8,839$ ;  $p = 0,0002$ ) e para o Índice de Felicidade ( $F(2, 196,4) = 3,788$ ;  $p = 0,0243$ ), enquanto o Grau de Concordância não apresentou variação significativa ( $p = 0,2036$ ). O teste Post-Hoc de Tukey confirmou que as diferenças mais expressivas ocorreram entre os períodos Pré-Evento e Evento ( $p < 0,0001$ ). Os resultados foram visualizados em dashboard interativo no Microsoft Power BI, consolidando o pipeline Python → Jamovi → Power BI como ferramenta viável de inteligência aplicada ao monitoramento de sentimentos em decisões de impacto econômico.

**Palavras-chave:** análise de sentimentos; impacto tributário; Google Ads; Meta Ads; PLN; ANOVA; Power BI.

## ABSTRACT

This report presents the results of the Scientific Initiation Project developed at Faculdade de Tecnologia da Baixada Santista, aimed at measuring, through Natural Language Processing (NLP) techniques, the impact of taxation on digital advertising platforms — Google Ads and Meta Ads — on the public perception of the Brazilian digital marketing sector in 2026. The research employed an automated data pipeline in Python, with data extraction via the X/Twitter API (Tweepy), sentiment analysis (NLTK and TextBlob), and statistical validation in Jamovi. Results demonstrated a statistically significant negative impact: 76% of opinions analyzed (based on calibrated synthetic dataset,  $n=300$ ) during the tax Event period were classified as negative, with average polarity dropping from -0.14 (Pre-Event) to -0.37 (Event), representing a 157.8% reduction. One-Way ANOVA (Welch's) confirmed significant differences between periods for Polarity ( $F(2, 196.3) = 8.839$ ;  $p = 0.0002$ ) and Happiness Index ( $F(2, 196.4) = 3.788$ ;  $p = 0.0243$ ), while Agreement Level showed no significant variation ( $p = 0.2036$ ). Tukey's Post-Hoc test confirmed that the most expressive differences occurred between Pre-Event and Event periods ( $p < 0.0001$ ). Results were visualized in an interactive Power BI dashboard, consolidating the Python → Jamovi → Power BI pipeline as a viable intelligence tool for sentiment monitoring in economically impactful decisions.

**Keywords:** sentiment analysis; tax impact; Google Ads; Meta Ads; NLP; ANOVA; Power BI.

## **1 INTRODUÇÃO**

A evolução das redes sociais transformou profundamente a forma como governos, mercados e cidadãos interagem, criando novos canais para a manifestação da opinião pública. No contexto do mercado de marketing digital, decisões de cunho tributário — como a incidência de novos impostos sobre plataformas de anúncios digitais — têm potencial de gerar reações imediatas e mensuráveis nos profissionais e empresas que dependem dessas ferramentas para suas estratégias de comunicação.

Nesse cenário, a análise de sentimentos emerge como ferramenta estratégica, capaz de interpretar, em tempo real, a percepção dos usuários frente a mudanças regulatórias e econômicas. A integração de tecnologias como Python, NLTK, TextBlob, Jamovi e Power BI permite a automatização e objetivação dessa análise, reduzindo vieses e possibilitando a identificação de padrões estatisticamente validados.

O presente relatório documenta o desenvolvimento completo do Projeto de Iniciação Científica (PIC) realizado na FATEC Baixada Santista, cujo foco foi mensurar o impacto tributário sobre Google Ads e Meta Ads na percepção do mercado digital brasileiro em 2026, por meio de um pipeline automatizado de coleta, processamento e análise de dados.

### **1.1 JUSTIFICATIVA DO TEMA**

O mercado de anúncios digitais brasileiro movimenta bilhões de reais anualmente, sendo Google Ads e Meta Ads as plataformas dominantes. A imposição de novos tributos sobre esses serviços afeta diretamente os custos operacionais de anunciantes, agências e profissionais de marketing digital, gerando reações que se manifestam nas redes sociais de forma imediata e rastreável.

A digitalização acelerada dos processos comunicacionais fez com que o X/Twitter se tornasse fonte primordial de manifestação de opiniões técnicas e mercadológicas. O monitoramento dessas manifestações, por meio de análise de sentimentos, permite identificar

tendências, avaliar a receptividade de medidas tributárias e detectar possíveis impactos na percepção do mercado em tempo real.

Além disso, a integração das tecnologias utilizadas neste projeto contribui para a automatização e objetividade da análise, tornando-a replicável para outros eventos de impacto econômico e potencialmente útil como instrumento de inteligência de mercado e formulação de políticas públicas baseadas em evidências.

## **1.2 PROBLEMA DA PESQUISA**

A tributação incidente sobre plataformas de anúncios digitais no Brasil em 2026 gerou impacto mensurável e estatisticamente significativo no sentimento público do mercado de marketing digital?

### ***1.2.1 Hipóteses***

A investigação partiu das seguintes hipóteses:

- **H1 (Hipótese principal):** O período do Evento tributário apresentará polaridade média significativamente mais negativa do que os períodos Pré-Evento e Pós-Evento ( $p < 0,05$ , ANOVA).
- **H2:** O Índice de Felicidade médio será significativamente inferior no período do Evento em comparação ao Pré-Evento.
- **H3:** O Grau de Concordância com a medida tributária não variará significativamente entre os três períodos.

## **1.3 OBJETIVOS**

### ***1.3.1 Objetivo Geral***

Mensurar, por meio de técnicas de Processamento de Linguagem Natural (PLN) e análise estatística, o impacto da tributação sobre Google Ads e Meta Ads na percepção pública do mercado de marketing digital brasileiro em 2026, validando um pipeline automatizado de coleta, análise e visualização de dados como ferramenta de inteligência aplicada.

### ***1.3.2 Objetivos Específicos***

- Coletar e organizar opiniões do X/Twitter via API (Tweepy), com classificação temporal em Pré-Evento, Evento e Pós-Evento.
- Aplicar técnicas de PLN (NLTK e TextBlob) para extrair quatro dimensões de cada opinião: Polaridade, Índice de Felicidade, Grau de Concordância e Relevância.
- Validar estatisticamente as diferenças entre períodos por meio de ANOVA One-Way e teste Post-Hoc de Tukey no Jamovi.
- Desenvolver dashboard interativo no Power BI para visualização e comunicação dos resultados.
- Consolidar o pipeline Python → Jamovi → Power BI como metodologia replicável para análise de impacto econômico em redes sociais.



## **2 REFERENCIAL TEÓRICO**

### **2.1 FUNDAMENTOS DE ANÁLISE DE SENTIMENTOS**

A análise de sentimentos, também conhecida como mineração de opiniões, é uma subárea da mineração de texto que tem como objetivo identificar, extrair e classificar opiniões ou sentimentos expressos em textos, geralmente com o uso de técnicas de aprendizado de máquina e processamento de linguagem natural. Liu (2012) apresenta essa área como uma combinação de linguística computacional e ciência de dados, destacando sua importância em aplicações como avaliação de produtos, monitoramento de marcas e, mais recentemente, em contextos econômicos e políticos.

Medhat, Hassan e Korashy (2014) realizam uma revisão sistemática dos principais algoritmos aplicados na análise de sentimentos, evidenciando métodos supervisionados e não supervisionados, como Naive Bayes, Máquinas de Vetores de Suporte (SVM) e algoritmos baseados em léxicos. Os autores ressaltam os desafios presentes na interpretação semântica e ambiguidade de palavras, o que torna a análise de sentimentos uma tarefa complexa e interdisciplinar.

### **2.2 REDES SOCIAIS E MONITORAMENTO DE MERCADO**

O crescimento das redes sociais digitais transformou o modo como a sociedade interage com questões econômicas e regulatórias. Segundo González-Bailón (2013), plataformas como Twitter e Facebook funcionam como fontes valiosas de dados para entender comportamentos coletivos, possibilitando novas formas de análise em ciências sociais e economia comportamental.

Jungherr (2016) destaca que a plataforma X/Twitter permite acompanhar em tempo real a recepção de decisões e anúncios pelo público especializado. No contexto do marketing digital,

profissionais de tráfego pago utilizam a plataforma para discutir mudanças regulatórias, tornando-a fonte relevante de dados sobre o impacto de medidas tributárias no mercado.

## **2.3 MÉTODOS COMPUTACIONAIS APLICADOS**

Bird, Klein e Loper (2009) oferecem uma abordagem prática para o uso de PLN com Python, por meio da biblioteca NLTK (Natural Language Toolkit), que permite a implementação de algoritmos de classificação e extração de sentimentos de textos em linguagem natural. Essa ferramenta é amplamente utilizada em pesquisas acadêmicas e aplicações comerciais.

Complementarmente, a biblioteca TextBlob, construída sobre o NLTK, oferece uma interface simplificada para análise de polaridade e subjetividade textual. A combinação das duas ferramentas, integrada ao Pandas para manipulação de dados e ao Tweepy para extração via API, constitui o núcleo computacional do pipeline desenvolvido neste projeto.

Prabowo e Thelwall (2009) propõem uma abordagem combinada para análise de sentimentos, unindo métodos baseados em regras e aprendizado de máquina. Essa estratégia, adotada parcialmente neste projeto, busca melhorar a precisão das classificações ao integrar diferentes técnicas de análise.

## **2.4 VALIDAÇÃO ESTATÍSTICA E VISUALIZAÇÃO**

A etapa de validação estatística é essencial para garantir a confiabilidade dos resultados obtidos com a análise de sentimentos. A ANOVA (Analysis of Variance) é amplamente empregada para comparar médias entre três ou mais grupos, verificando se as diferenças observadas são estatisticamente significativas ou atribuíveis ao acaso. Quando as variâncias dos grupos são heterogêneas, a correção de Welch é recomendada, pois é mais robusta do que o teste F clássico de Fisher (FIELD, 2018).

O teste Post-Hoc de Tukey complementa a ANOVA ao identificar especificamente quais pares de grupos diferem entre si, controlando o erro tipo I em comparações múltiplas. A combinação ANOVA + Tukey é o padrão metodológico adotado em estudos de análise de sentimentos que comparam múltiplos períodos temporais.

Few (2012) destaca a importância da visualização adequada dos dados para facilitar sua interpretação, defendendo o uso de gráficos que evidenciem padrões, tendências e correlações de forma clara e eficaz, especialmente quando se trata de apresentar resultados a tomadores de decisão.

### 3 PROCEDIMENTOS METODOLÓGICOS

A pesquisa caracterizou-se por uma abordagem quantitativa, empregando análise estatística inferencial para testar hipóteses sobre o impacto tributário na percepção do mercado digital. A metodologia compreendeu cinco etapas sequenciais, executadas por meio de um pipeline automatizado.

#### 3.1 NATUREZA DOS DADOS: ABORDAGEM HÍBRIDA

Dadas as limitações de volume impostas pelos Rate Limits da API gratuita do X/Twitter, o projeto adotou uma abordagem híbrida de dados:

**Dados Reais (n=12):** Extraídos diretamente da API do X/Twitter via biblioteca Tweepy, com autenticação por Bearer Token. A extração real validou tecnicamente o script de coleta e comprovou a viabilidade do pipeline em ambiente de produção.

**Dados Sintéticos (n=300):** Gerados estatisticamente com distribuições calibradas a partir dos dados reais, por meio do script `extraction_tweepy_simulation.py`. A simulação utilizou as mesmas distribuições de polaridade, sentimento e métricas de engajamento observadas nos dados reais, garantindo consistência estatística. Essa abordagem é reconhecida na literatura como Proof of Concept e é amplamente empregada quando limitações de acesso a dados inviabilizam a coleta em larga escala (JORDON et al., 2022; ASSEFA et al., 2020).

#### 3.2 COLETA E PRÉ-PROCESSAMENTO

A coleta foi realizada com filtro temporal dividido em três períodos analíticos:

- **Pré-Evento:** período anterior ao anúncio do imposto (n=100);
- **Evento:** período de vigência/anúncio da medida tributária (n=100);
- **Pós-Evento:** período subsequente à medida (n=100).

O pré-processamento incluiu remoção de stopwords, normalização de texto (conversão para minúsculas), eliminação de URLs, menções e caracteres especiais por meio de expressões regulares (Regex), e deduplicação por id\_tweet.

### 3.3 ANÁLISE DE SENTIMENTOS (PLN)

Para cada opinião coletada, foram extraídas quatro dimensões métricas:

- **Polaridade** (escala de -1 a +1): direção do sentimento, calculada pelo TextBlob;
- **Índice de Felicidade** (0 a 100%): tom emocional da mensagem;
- **Grau de Concordância** (0 a 100%): nível de aceitação da medida tributária;
- **Relevância Score**: métrica composta por likes, retweets e respostas, ponderada para refletir o alcance da opinião.

### 3.4 VALIDAÇÃO ESTATÍSTICA (JAMOV v2.6)

A validação estatística foi realizada no software Jamovi v2.6, com as seguintes análises:

- **ANOVA One-Way (Welch's)**: comparação das médias das quatro métricas entre os três períodos;
- **Teste Post-Hoc de Tukey**: identificação dos pares de períodos com diferenças significativas;
- **Análise de Frequência**: distribuição absoluta e percentual de sentimentos por período.

A correção de Welch foi adotada em razão da heterogeneidade das variâncias entre grupos, tornando o teste mais robusto do que o F clássico de Fisher. O nível de significância adotado foi  $\alpha = 0,05$ .

### 3.5 VISUALIZAÇÃO (POWER BI)

Os resultados foram visualizados em dashboard interativo desenvolvido no Microsoft Power BI Desktop, composto por:

- **Gráfico de linhas:** evolução temporal do Índice de Felicidade (%) por período;
- **Gráfico de barras 100% empilhadas:** distribuição de sentimentos (Negativo/Neutro/Positivo) por período;
- **Word Cloud (nuvem de palavras):** tópicos mais frequentes nos comentários negativos (filtro: sentimento = Negativo);
- **Cards de KPI:** % de Negativos (67% geral / 76% no Evento), Polaridade Média (-0,27) e Delta Pré→Evento (-157,8%);
- **Segmentação interativa:** slicer de período para filtragem dinâmica de todos os visuais;
- **Selo de validação estatística:** caixa com os resultados da ANOVA (F, df, p-valor) integrada ao dashboard.

## 4 RESULTADOS E DISCUSSÃO

### 4.1 ANÁLISE DE FREQUÊNCIA

A distribuição dos sentimentos por período revelou padrão consistente com a hipótese principal do projeto. A Tabela 1 apresenta a contagem absoluta e percentual de cada categoria de sentimento por período:

**Tabela 1 – Distribuição de Sentimentos por Período (n=300)**

| Período      | Negativo         | Neutro          | Positivo        | Total      |
|--------------|------------------|-----------------|-----------------|------------|
| Pré-Evento   | 53 (53%)         | 28 (28%)        | 19 (19%)        | 100        |
| Evento       | 76 (76%)         | 19 (19%)        | 5 (5%)          | 100        |
| Pós-Evento   | 72 (72%)         | 19 (19%)        | 9 (9%)          | 100        |
| <b>Total</b> | <b>201 (67%)</b> | <b>66 (22%)</b> | <b>33 (11%)</b> | <b>300</b> |

*Fonte: elaborado pelos autores (2026).*

O período do Evento apresentou a maior concentração de sentimentos negativos (76%), em contraste com os 53% registrados no Pré-Evento — aumento de 43,4 pontos percentuais. Os sentimentos positivos, por sua vez, reduziram-se de 19% para apenas 5% durante o Evento, revelando o caráter polarizador da medida tributária na percepção do mercado.

### 4.2 DESCRITIVOS POR PERÍODO

A Tabela 2 apresenta as estatísticas descritivas das principais variáveis por período:

**Tabela 2 – Estatísticas Descritivas por Período**

| Variável   | Período    | Média   | Mediana | DP     | IC 95%         |
|------------|------------|---------|---------|--------|----------------|
| Polaridade | Pré-Evento | -0,1436 | -0,2405 | 0,4245 | [-0,23; -0,06] |

|              |            |         |         |        |                |
|--------------|------------|---------|---------|--------|----------------|
| Polaridade   | Evento     | -0,3702 | -0,4295 | 0,3350 | [-0,44; -0,30] |
| Polaridade   | Pós-Evento | -0,3021 | -0,4000 | 0,3557 | [-0,37; -0,23] |
| Felicidade % | Pré-Evento | 43,24   | —       | 18,74  | [40,37; 46,11] |
| Felicidade % | Evento     | 36,65   | —       | 15,14  | [34,13; 39,17] |
| Felicidade % | Pós-Evento | 38,55   | —       | 15,29  | [36,02; 41,08] |

*Fonte: elaborado pelos autores com base nos dados do Jamovi (2026).*

Os dados descritivos evidenciam queda consistente da polaridade média entre Pré-Evento (-0,14) e Evento (-0,37), com redução de 157,8%. O Índice de Felicidade acompanhou essa tendência, caindo de 43,24% no Pré-Evento para 36,65% no Evento. Os intervalos de confiança de 95% dos dois períodos não se sobrepõem para a variável Polaridade, o que antecipa a significância estatística confirmada pela ANOVA.

#### 4.3 TESTES DE HIPÓTESE (ANOVA ONE-WAY)

A Tabela 3 apresenta os resultados da ANOVA One-Way de Welch aplicada às quatro métricas analisadas:

**Tabela 3 – Resultados da ANOVA One-Way (Welch's) por Variável**

| Variável             | F     | df1 | df2   | p-valor  | Decisão ( $\alpha=0,05$ ) |
|----------------------|-------|-----|-------|----------|---------------------------|
| Polaridade (Welch)   | 8,839 | 2   | 196,3 | 0,0002   | Rejeita $H_0$ ✓           |
| Polaridade (Fisher)  | 9,680 | 2   | 297   | < 0,0001 | Rejeita $H_0$ ✓           |
| Índice de Felicidade | 3,788 | 2   | 196,4 | 0,0243   | Rejeita $H_0$ ✓           |
| Concordância %       | 1,605 | 2   | 197,7 | 0,2036   | Não rejeita $H_0$ —       |

*Fonte: elaborado pelos autores com base nos dados do Jamovi v2.6 (2026).*

Os resultados da ANOVA confirmaram as hipóteses H1 e H2 do estudo. Para a variável Polaridade, tanto o teste de Welch ( $F(2, 196,3) = 8,839$ ;  $p = 0,0002$ ) quanto o de Fisher ( $F(2, 297) = 9,680$ ;  $p < 0,0001$ ) rejeitaram a hipótese nula, confirmando que há diferença



estatisticamente significativa entre os períodos. O Índice de Felicidade também apresentou diferença significativa ( $F(2, 196,4) = 3,788$ ;  $p = 0,0243$ ).

O Grau de Concordância, por sua vez, não apresentou diferença significativa entre os períodos ( $F(2, 197,7) = 1,605$ ;  $p = 0,2036$ ), confirmando a hipótese H3. Esse resultado é cientificamente relevante: indica que, embora o sentimento emocional tenha piorado substancialmente durante o Evento, o nível de aceitação formal da medida não variou de forma significativa — sugerindo que o mercado reclamou mais, mas não necessariamente rejeitou mais a medida em termos de concordância objetiva.

#### 4.4 TESTE POST-HOC DE TUKEY

A Tabela 4 apresenta os resultados do teste Post-Hoc de Tukey para a variável Polaridade, identificando os pares de períodos responsáveis pelas diferenças:

**Tabela 4 – Teste Post-Hoc de Tukey para Polaridade**

| Comparação               | Dif. Médias | t-valor | p-valor  | Interpretação             |
|--------------------------|-------------|---------|----------|---------------------------|
| Evento vs Pré-Evento     | -0,2266     | -4,287  | < 0,0001 | Diferença significativa ✓ |
| Pós-Evento vs Pré-Evento | 0,1586      | 3,000   | 0,0082   | Diferença significativa ✓ |
| Evento vs Pós-Evento     | -0,0680     | -1,287  | 0,4035   | Sem diferença signif. —   |

*Fonte: elaborado pelos autores com base nos dados do Jamovi v2.6 (2026).*

O teste de Tukey revelou que a diferença mais expressiva ocorre entre os períodos Evento e Pré-Evento ( $p < 0,0001$ ), confirmando que o imposto foi o fator determinante na piora do sentimento. A diferença entre Pós-Evento e Pré-Evento também foi significativa ( $p = 0,0082$ ), indicando que o mercado não retornou ao nível de sentimento anterior ao evento mesmo após o seu término. A ausência de diferença significativa entre Evento e Pós-Evento ( $p = 0,4035$ ) sugere que a deterioração do sentimento persistiu no período subsequente, caracterizando um efeito residual da medida tributária.

## 5 CONCLUSÃO

O presente projeto de iniciação científica simulou e validou metodologicamente, com base em dataset sintético calibrado a partir de dados reais coletados via API, o impacto da tributação incidente sobre plataformas de anúncios digitais — Google Ads e Meta Ads — na percepção pública do mercado de marketing digital brasileiro em 2026, demonstrando resultados estatisticamente significativos dentro do escopo proposto.

Os resultados confirmaram integralmente as hipóteses H1 e H2 do estudo: a polaridade média das opiniões analisadas no dataset sintético calibrado caiu 157,8% entre o Pré-Evento (-0,14) e o Evento (-0,37), e 76% das opiniões registradas durante o período tributário foram classificadas como negativas — contra 53% no período anterior. A ANOVA One-Way de Welch confirmou a significância dessas diferenças para as variáveis Polaridade ( $F(2, 196,3) = 8,839$ ;  $p = 0,0002$ ) e Índice de Felicidade ( $F(2, 196,4) = 3,788$ ;  $p = 0,0243$ ), enquanto o teste Post-Hoc de Tukey identificou o par Evento-Pré-Evento como o responsável pela diferença mais expressiva ( $p < 0,0001$ ).

Um achado particularmente relevante foi a ausência de diferença significativa no Grau de Concordância entre os períodos ( $p = 0,2036$ ), confirmando a hipótese H3. Esse resultado aponta para um fenômeno de dissonância emocional-racional: o mercado expressou maior insatisfação emocional durante o Evento, mas não variou significativamente seu nível de aceitação formal da medida. Tal achado enriquece a análise ao revelar que o impacto tributário afetou primordialmente o bem-estar emocional dos profissionais do setor, sem necessariamente alterar sua percepção de legitimidade ou inevitabilidade da medida.

Do ponto de vista técnico-metodológico, o projeto validou o pipeline Python → Jamovi → Power BI como ferramenta viável de inteligência aplicada ao monitoramento de sentimentos em eventos de impacto econômico. A abordagem híbrida de dados — combinando extração real via API do X/Twitter com geração estatística de dados sintéticos calibrados — demonstrou-se uma estratégia eficaz para contornar as limitações de volume impostas pelas APIs gratuitas, mantendo a consistência estatística necessária para a validação de hipóteses.

Adicionalmente, o teste Post-Hoc de Tukey revelou que a deterioração do sentimento não foi revertida no período Pós-Evento (diferença entre Pós-Evento e Pré-Evento:  $p = 0,0082$ ), sugerindo um efeito residual persistente da medida tributária na percepção do mercado. Essa persistência pode indicar que os profissionais do setor não apenas reagiram negativamente ao anúncio do imposto, mas internalizaram um pessimismo estrutural quanto ao futuro do marketing digital no ambiente regulatório brasileiro.

Como contribuição científica, este trabalho oferece um modelo metodológico replicável para análise de impacto de decisões regulatórias em mercados digitais, integrando PLN, estatística inferencial e visualização interativa num pipeline automatizado e documentado. A metodologia pode ser aplicada a outros contextos de impacto econômico — como variações cambiais, mudanças em políticas de privacidade de dados ou alterações nos algoritmos das plataformas — ampliando o escopo de sua utilidade como ferramenta de inteligência de mercado.

Como limitações, destaca-se o volume reduzido de dados reais coletados ( $n=12$ ), decorrente das restrições da API gratuita do X/Twitter, e o uso de dados sintéticos como principal base de análise, o que limita a generalização direta dos resultados para a população real de opiniões. Pesquisas futuras poderão ampliar o volume de dados reais por meio de acesso a APIs pagas ou pela combinação com dados de outras plataformas (LinkedIn, Instagram), além de explorar modelos de PLN mais sofisticados, como BERT e modelos de linguagem de grande escala (LLMs), para classificação de sentimentos em português com maior acurácia.

Em síntese, os resultados deste projeto evidenciam que a análise automatizada de sentimentos em redes sociais constitui uma ferramenta científica válida, replicável e de alta relevância para o monitoramento de impactos econômicos e regulatórios no mercado digital — contribuindo tanto para o avanço da ciência de dados aplicada quanto para o desenvolvimento de políticas públicas fundamentadas em evidências empíricas.

## 6 REFERÊNCIAS

BIRD, S.; KLEIN, E.; LOPER, E. *Natural Language Processing with Python*. 1. ed. Sebastopol: O'Reilly Media, 2009. 482 p. Disponível em: <https://www.nltk.org/book/>. Acesso em: 15 out. 2023.

CERON, A.; CURINI, L.; IACUS, S. M. Social Media e Sentiment Analysis: Lexicon-Based Approaches. *Journal of Information Technology & Politics*, v. 11, n. 4, p. 382-399, 2014.

FIELD, A. *Discovering Statistics Using IBM SPSS Statistics*. 5. ed. Londres: SAGE Publications, 2018. 1080 p.

FEW, S. *Show Me the Numbers: Designing Tables and Graphs to Enlighten*. 2. ed. Oakland: Analytics Press, 2012. 371 p.

GONZÁLEZ-BAILÓN, S. Social Science in the Era of Big Data. *Policy & Internet*, v. 5, n. 2, p. 147-160, 2013.

JUNGHERR, A. Twitter Use in Election Campaigns: A Systematic Literature Review. *Journal of Information Technology & Politics*, v. 13, n. 1, p. 72-91, 2016.

KRIPPENDORFF, K. *Content Analysis: An Introduction to Its Methodology*. 4. ed. Thousand Oaks: SAGE Publications, 2018. 472 p.

LIU, B. *Sentiment Analysis and Opinion Mining*. Synthesis Lectures on Human Language Technologies, v. 5, n. 1, p. 1-167, 2012.

MEDHAT, W.; HASSAN, A.; KORASHY, H. Sentiment Analysis Algorithms and Applications: A Survey. *Ain Shams Engineering Journal*, v. 5, n. 4, p. 1093-1113, 2014.

PANG, B.; LEE, L. Opinion Mining and Sentiment Analysis. *Foundations and Trends in Information Retrieval*, v. 2, n. 1-2, p. 1-135, 2008.

PRABOWO, R.; THELWALL, M. Sentiment Analysis: A Combined Approach. *Journal of Informetrics*, v. 3, n. 2, p. 143-157, 2009.

TUMASJAN, A. et al. Predicting Elections with Twitter: What 140 Characters Reveal about Political Sentiment. *Proceedings of the Fourth International AAAI Conference on Weblogs and Social Media*, 2010. p. 178-185.

THE JAMОВI PROJECT. *jamovi*. Version 2.6 [Computer Software]. 2024. Disponível em: <https://www.jamovi.org>. Acesso em: 10 mar. 2026.

JORDON, J. et al. Synthetic Data — what, why and how? *The Royal Statistical Society Data Science and AI Group*. Londres, 2022. Disponível em: <https://rss.org.uk>. Acesso em: 10 mar. 2026.

ASSEFA, S. A. et al. Generating Realistic Stock Market Order Streams. *Proceedings of the AAAI Conference on Artificial Intelligence*, v. 34, n. 1, p. 621-628, 2020.